

INFORME EJECUTIVO

StreamView Analytics: ¿dónde invertir el presupuesto de contenido?

Solución integral de Visual Analytics sobre un catálogo de 31.991 títulos
(2010–2025)

**Pregunta central: ¿Qué segmentos del catálogo — formato, género, país —
concentran mayor engagement y mejor percepción de calidad, y cómo debería
StreamView priorizar su inversión de contenido?**

Asignatura: ADY1104 — Visualización de Datos

Docente: Guillermo Pinto

Integrantes: Genesis Baeza · Jimena Galicia

Duoc UC — Escuela de Informática y Telecomunicaciones

1. Descripción del problema de negocio

StreamView Analytics es una plataforma internacional de streaming digital, fundada en 2018, que distribuye contenido audiovisual en distintos mercados de Latinoamérica bajo un modelo de suscripción. Tras años de crecimiento sostenido, la organización administra hoy un catálogo de decenas de miles de títulos provenientes de múltiples países, idiomas y géneros.

Su ventaja competitiva depende de tres palancas que la Dirección de Contenido monitorea de forma permanente: la **retención de suscriptores**, el **nivel de interacción (engagement)** con el catálogo y el **acierto en las preferencias de consumo**. Sin embargo, el crecimiento del catálogo ha superado la capacidad de la organización para leerlo de forma consolidada.

1.1 Contexto organizacional: el síntoma

El problema de StreamView no es la ausencia de datos, sino su fragmentación. Cada área construye reportes independientes con criterios propios, lo que produce cuatro consecuencias documentadas en la reunión anual del Directorio:

- Conviven **múltiples versiones de un mismo indicador**, sin una fuente única de verdad.
- Los ejecutivos dedican gran parte de su tiempo a **interpretar reportes** en lugar de decidir.
- Las decisiones de adquisición de contenido se toman con **información parcial**.
- Resulta difícil **comunicar tendencias** de manera clara y consistente entre áreas.

1.2 El encargo

La Gerencia General contrató a este equipo consultor, especializado en analítica y comunicación visual de datos, para construir una solución de Visual Analytics que transforme el catálogo corporativo en evidencia accionable. El alcance excluye explícitamente el desarrollo de modelos predictivos, algoritmos de inteligencia artificial y procesos ETL: el objetivo es **comunicar información para apoyar decisiones**, no predecir.

Pregunta de negocio que este proyecto responde: ¿qué segmentos del catálogo — formato, género, país — concentran mayor engagement y mejor percepción de calidad, y cómo debería StreamView priorizar su inversión de contenido?

2. Objetivos del proyecto

2.1 Objetivo general

Diseñar e implementar una solución integral de Visual Analytics que permita comunicar información relevante del catálogo audiovisual de StreamView Analytics mediante dashboards interactivos, narrativas visuales y productos gráficos que apoyen la toma de decisiones estratégicas de inversión de contenido.

2.2 Objetivos específicos

- **Caracterizar el catálogo** audiovisual integrando las fuentes de Películas y Series en una única tabla analítica coherente.
- **Analizar la distribución** de contenidos por país, idioma y género, identificando qué comparaciones son estadísticamente válidas y cuáles no.

- **Comparar popularidad y valoración** entre formatos y determinar si constituyen señales equivalentes o independientes.
- **Auditar la calidad de los datos** antes de visualizar, documentando cada decisión de limpieza y cada variable descartada.
- **Construir un dashboard ejecutivo** con KPIs, filtros, navegación e interacción, orientado a un perfil directivo no técnico.
- **Aplicar principios de percepción visual y storytelling** para comunicar los hallazgos, justificando técnicamente cada representación gráfica seleccionada.
- **Formular recomendaciones sustentadas en evidencia**, explicitando el grado de certeza que los datos disponibles permiten sostener.

3. Audiencia objetivo y propósito comunicacional

3.1 Caracterización de la audiencia

La definición de la audiencia no fue un trámite formal: condicionó todas las decisiones de diseño posteriores, desde la selección de gráficos hasta la redacción de los títulos.

Audiencia	Perfil	Necesidad de información
Comité Directivo de Contenido (primaria)	CCO, VP de Estrategia, Dirección General. Perfil ejecutivo, sin formación estadística.	Indicadores consolidados, tendencias y comparaciones que permitan decidir dónde asignar presupuesto de contenido.
Equipo Data & Analytics (secundaria)	Perfil técnico, responsable de mantener los dashboards corporativos.	Código reproducible y documentado, decisiones de limpieza trazables.
Marketing / Comunicación (secundaria)	Responsable de campañas promocionales.	Qué contenidos y categorías priorizar en campañas.

3.2 Propósito comunicacional

Comunicar, con evidencia verificable, **en qué segmentos del catálogo conviene concentrar la inversión de contenido — y en cuáles conviene ser cauteloso —** mediante una narrativa visual breve, interactiva y jerarquizada, capaz de resistir preguntas cruzadas en una defensa técnica en vivo.

3.3 Consecuencias de diseño

Un comité ejecutivo no lee tablas de coeficientes: lee titulares, compara barras y confía en un color cuando ya sabe lo que significa. De ese perfil se derivan tres reglas que gobiernan toda la solución:

- **Títulos comunicacionales, no descriptivos.** Cada gráfico se titula con el hallazgo ("Las Series superan a las Películas en 5 de 8 géneros") y no con el tema ("Volumen por género"), de modo que la conclusión llegue antes que la necesidad de interpretar.
- **Detalle bajo demanda.** El mensaje principal es visible de inmediato; el detalle granular (título exacto, cifras precisas) se reserva para la interacción de *hover*.
- **Paleta de dos colores con significado fijo.** Ámbar para Películas, azul marino para Series, idénticos en notebook, dashboard y presentación.

4. Descripción e integración de las fuentes de datos

StreamView Analytics puso a disposición del equipo consultor dos conjuntos de datos corporativos, correspondientes a un extracto anonimizado del catálogo enriquecido con metadatos de bases de datos cinematográficas internacionales.

Fuente	Registros	Variables	Particularidad
<code>netflix_movies_detailed_up_to_2025.csv</code>	16.000	18	Incluye budget y revenue , ausentes en el catálogo de Series.
<code>netflix_tv_shows_detailed_up_to_2025.csv</code>	16.000	16	Sin variables financieras.

4.1 Proceso de integración

Ambas fuentes se integraron en una única tabla analítica, **df_catálogo**, conservando las 15 columnas comunes a las dos y añadiendo una variable derivada **content_type** que distingue el formato. El resultado son **31.991 títulos**: 16.000 películas y 15.991 series (nueve registros duplicados por identificador fueron eliminados del catálogo de Series).

Decisión técnica relevante: la variable `show_id` tiene numeración independiente en cada catálogo — existen cientos de identificadores que coinciden numéricamente sin corresponder al mismo título. Integrar directamente por `show_id` habría fusionado títulos distintos. Por ello se construyó una clave propia, `id_unico`, anteponiendo el tipo de contenido al identificador original.

4.2 Variables relevantes para el análisis

Variable	Tipo de dato	Uso en el análisis
content_type	Categoría (derivada)	Formato: Película o Serie TV. Eje comparativo central de todo el proyecto.
genres · country	Categorías multivaluadas	Un título puede tener varios valores separados por coma; requieren expansión (<code>explode</code>) antes de agrupar.
release_year	Temporal (2010–2025)	Único eje temporal utilizable del catálogo.
popularity	Númerica continua	Índice relativo de interés reciente. Proxy de engagement. Según la regla de negocio 5 del caso, no representa cantidad de reproducciones .
vote_average	Númerica continua (0–10)	Calificación promedio de audiencia. Proxy de calidad percibida.
vote_count	Númerica discreta	Volumen de evaluaciones recibidas. Proxy de alcance y, sobre todo, de madurez del dato .

4.3 Variables descartadas y su justificación

La auditoría de calidad previa a cualquier visualización descartó cuatro variables. Documentarlas es tan relevante como documentar las que se usaron, porque delimita lo que el análisis puede y no puede afirmar:

Variable	Hallazgo verificado	Decisión
duration	100 % nula en Películas; constante ("1 Seasons") en el 100 % de las Series.	Eliminada: no aporta información.
rating	Idéntica a <i>vote_average</i> en el 100 % de las filas de ambas fuentes.	Eliminada por redundante.
date_added	El año coincide con <i>release_year</i> en el 100 % de los registros.	No utilizada: impide distinguir fecha de estreno de fecha de incorporación al catálogo.
budget · revenue	69,7 % y 64,7 % de valores en cero respectivamente; existen solo para Películas.	Excluidas del análisis visual principal, conforme a la regla de negocio 6 del caso.

5. Análisis exploratorio mediante visualizaciones

El análisis exploratorio no solo describió el catálogo: identificó tres patrones que modificaron el diseño de todas las visualizaciones posteriores. Se documentan aquí porque constituyen el ejemplo más claro de por qué la auditoría debe preceder al diseño gráfico.

5.1 Hallazgo crítico: el catálogo es una muestra curada

Al examinar la distribución de títulos por año de lanzamiento se detectó que cada fuente contiene **exactamente 1.000 títulos por año, todos los años, entre 2010 y 2025**, sin variación alguna. Esa uniformidad perfecta no corresponde al crecimiento orgánico de un catálogo real: indica una muestra estratificada construida por diseño.

Consecuencia de diseño: el proyecto descartó deliberadamente construir un gráfico de "volumen de contenido a lo largo del tiempo". Habría sido una línea perfectamente recta por construcción muestral: técnicamente correcto, pero **comunicacionalmente engañoso**, porque un directivo lo leería como estabilidad estratégica del catálogo cuando en realidad es un artefacto del muestreo.

5.2 Hallazgo crítico: sesgo de arranque en frío

Los títulos más recientes muestran una caída pronunciada en el número de votos acumulados: en Películas, el promedio pasa de **871 votos en 2019 a 11 votos en 2025**. La misma caída aparece en el índice de popularidad.

Sin embargo — y este es el punto decisivo — **la calificación promedio no cae de la misma forma**. Esto confirma que el fenómeno es un artefacto del *tiempo de acumulación de votos* y no una señal real de que el contenido reciente sea de peor calidad: un título estrenado hace unos meses aún no ha tenido tiempo de acumular evaluaciones, pero las que tiene son igual de válidas.

Consecuencia de diseño: toda comparación de popularidad entre títulos aplica un umbral mínimo de votos acumulados. Comparar un título de 2025 con once votos contra uno de 2015 con miles no sería una comparación justa. El dashboard expone ese umbral como filtro para que el usuario pueda observar el efecto por sí mismo.

5.3 Hallazgo crítico: taxonomías de género incompatibles

Los catálogos de Películas y Series emplean clasificaciones de género distintas en la fuente original: donde uno registra "Action" y "Science Fiction", el otro agrupa "Action & Adventure" y "Sci-Fi & Fantasy". Solo **ocho etiquetas son textualmente idénticas** en ambos catálogos: Drama, Comedy, Animation, Crime, Family, Mystery, Documentary y Western. Toda comparación de género entre formatos se restringe a esas ocho categorías; forzar equivalencias entre taxonomías distintas habría producido comparaciones inválidas.

5.4 Otros patrones relevantes

- **Distribuciones asimétricas.** *popularity* y *vote_count* presentan colas largas hacia la derecha: unos pocos títulos extremadamente populares elevan el promedio muy por encima de la mediana. *vote_average*, en cambio, se distribuye de forma simétrica en torno a 6–7. De ahí la decisión de usar escala logarítmica y mediana (no promedio) para las métricas de popularidad.
- **Diversidad internacional real.** El catálogo abarca 147 países y 83 idiomas. El inglés concentra el 43,7 % de los títulos, pero chino, japonés y coreano suman en conjunto un 24,6 %: aproximadamente una cuarta parte del catálogo.

- **Ausencia de calificación.** 899 películas y 3.665 series registran *vote_average* = 0, valor que coincide con *vote_count* $\approx$ 0. Se trata de **ausencia de datos**, no de una calificación real de 0/10, por lo que se marcaron con una bandera y se excluyen de todos los promedios de calificación.

6. Justificación de las representaciones gráficas seleccionadas

Cada visualización se seleccionó a partir de tres criterios: la **naturaleza del dato** a representar, el **atributo preatentivo** más preciso disponible para la comparación principal, y el efecto de la decisión sobre la **carga cognitiva** del lector.

6.1 Marco conceptual aplicado

Los atributos preatentivos son propiedades visuales que el sistema perceptual procesa en paralelo, sin atención consciente, en menos de 250 milisegundos. No todos tienen la misma precisión: la **posición** y la **longitud** permiten juicios cuantitativos exactos, mientras que el **área**, la **intensidad** y el **color** solo admiten comparaciones aproximadas. El criterio rector del proyecto fue asignar siempre la variable más importante al atributo perceptualmente más preciso disponible.

Gráfico	Tipo de dato	Justificación técnica
1. Barras horizontales Volumen por género	Categorica × categorica → conteo	La longitud codifica la comparación principal, por ser el atributo preatentivo de mayor precisión perceptual. La proximidad (Gestalt) agrupa la barra de Película y la de Serie dentro de cada género, de modo que el par comparable se percibe sin búsqueda activa. Orientación horizontal para que las etiquetas se lean sin rotar.
2. Líneas Evolución de calificación	Temporal continua × numérica	El principio de conexión (Gestalt) es lo que hace funcionar este gráfico: al unir los puntos, dieciséis observaciones anuales se perciben como una sola tendencia en vez de saturar la memoria de trabajo con comparaciones punto a punto. El eje Y acotado (5,5–8) es legítimo aquí porque la comparación es de posición y pendiente , no de longitud: truncar distorsiona en barras, no en líneas.
3. Dispersión Popularidad vs. calificación	Numérica continua × numérica continua	La posición (x, y) es el atributo preatentivo principal. La opacidad reducida (35 %) revela la densidad por superposición sin introducir ninguna variable visual nueva. La escala logarítmica corrige la asimetría de la popularidad: en escala lineal, unos pocos títulos virales comprimirían el resto del catálogo contra el eje.
4. Barras + color secuencial Países productores	Categorica × dos numéricas	La longitud mantiene el volumen y el color añade la calificación en una escala de un solo matiz. Se evitó una escala tipo semáforo porque la calificación es un continuo: una escala multicolor inventaría categorías inexistentes en el dato.
5. Burbujas Portafolio de géneros	Dos numéricas + tamaño + categoría	Permite comparar tres magnitudes por género sin recurrir a una tabla. La variable menos crítica (volumen) se asigna deliberadamente al atributo menos preciso (tamaño), para que no compita con la comparación principal.

6.2 Coherencia cromática transversal

La paleta se definió una sola vez y se reutiliza sin excepción en el notebook, el dashboard y la presentación: **ámbar #C97B30** para Películas y **azul marino #0B3D62** para Series, con un gris neutro para líneas de referencia y un coral reservado exclusivamente para destacar un hallazgo puntual. Esto aplica el principio de **similitud** (Gestalt): un mismo color significa siempre lo mismo, de modo que la audiencia decodifica el código una única vez y no vuelve a gastar atención en releer leyendas.

6.3 Reducción sistemática de la carga cognitiva

- **Títulos que comunican el hallazgo**, no el contenido del gráfico, para entregar la conclusión antes de exigir interpretación.
- **Etiquetas de valor sobre las barras**, evitando que el lector interpole contra el eje.
- **Anotación selectiva**: en el gráfico de burbujas solo dos de veintiséis se etiquetan de forma permanente; el resto se revela por *hover*. Veintiséis etiquetas simultáneas serían ilegibles.
- **Recorte deliberado de categorías**: el ranking de países se limita a los diez principales, y no a los 147 presentes en los datos.

7. Desarrollo de la narrativa visual (Data Storytelling)

Los hallazgos se organizaron en una narrativa de cuatro movimientos, deliberadamente libre de jerga técnica, dirigida al Comité Directivo de Contenido.

Movimiento 1 — Contexto

StreamView Analytics necesita decidir dónde concentrar su inversión de contenido entre formatos, géneros y mercados. Para responderlo se analizó el catálogo completo: 31.991 títulos lanzados entre 2010 y 2025, utilizando popularidad, volumen de votos y calificación de audiencia como aproximaciones de engagement y calidad percibida.

Movimiento 2 — Hallazgo principal

Las Series TV superan de forma sistemática a las Películas. En calificación de audiencia promedian 7,03 sobre 10 frente a 6,31 de las Películas — una brecha de 0,72 puntos — y su popularidad mediana es más de tres veces superior. La ventaja no es un artefacto de un año puntual ni de un género de moda: se sostiene durante los dieciséis años analizados, en cinco de los ocho géneros directamente comparables, y los géneros mejor evaluados de todo el catálogo integrado son, sin excepción, géneros de Serie.

Movimiento 3 — Evidencia e implicancia

- El **gráfico de volumen por género** muestra que las Series ya igualan o superan a las Películas en la mayoría de los géneros con taxonomía comparable.
- El **gráfico de evolución temporal** confirma que la brecha de calificación es estructural: las líneas nunca se cruzan en dieciséis años. Si fuera ruido estadístico, se habrían cruzado.
- El **análisis por país** añade el eje geográfico: Japón y China no solo aportan volumen relevante de Series, sino también las calificaciones más altas del top 10.
- El **gráfico de dispersión** matiza la conclusión de forma decisiva: popularidad y calificación están débilmente correlacionadas ($r \approx 0,16$). Son señales casi independientes.

La implicancia para el negocio es directa: el formato Serie constituye hoy el motor más confiable de engagement y satisfacción del catálogo, pero optimizar la cartera por una sola métrica sacrificaría la otra sin que nadie lo advierta. Un plan basado solo en alcance premiaría títulos masivos de calidad mediocre y descartaría piezas excelentes de audiencia reducida.

Movimiento 4 — Acción

Las recomendaciones derivadas se desarrollan en la Sección 10. En síntesis: reorientar el mix hacia Series en los géneros y mercados ya validados, proteger Documental como apuesta de calidad de nicho, auditar la sobre-inversión en Horror y adoptar un indicador compuesto para las decisiones de luz verde.

8. Diseño e implementación del dashboard interactivo

El dashboard se desarrolló en **Streamlit** con visualizaciones en **Plotly**. A diferencia del informe, que entrega una narrativa guiada, el dashboard permite al Comité formular sus propias preguntas al catálogo sin depender del equipo consultor.

Componente	Implementación
Indicadores clave (KPIs)	Cinco indicadores que se recalculan dinámicamente con cada filtro: títulos en la selección, calificación promedio, popularidad mediana, porcentaje de Series y género principal. Cada uno incluye una definición accesible por <i>hover</i> .
Filtros	Tipo de contenido, rango de año de lanzamiento, mínimo de votos acumulados y género. El filtro de votos mínimos expone el sesgo de arranque en frío para que el usuario observe su efecto en vivo.
Navegación	Seis pestañas: Resumen, Géneros, Evolución temporal, Popularidad vs. Calificación, Países y Explorar datos.
Interacción	<i>Hover</i> con detalle por título y zoom en todos los gráficos; tabla filtrable y ordenable; exportación de la selección activa a CSV.

8.1 Principios de percepción aplicados a la interfaz

- **Cercado (Gestalt).** Los cinco KPIs viven dentro de tarjetas con borde y fondo propios. El límite visual explícito hace que se perciban como un grupo único y no como cinco cifras sueltas, aliviando el trabajo de agruparlas mentalmente.
- **Espacio en blanco.** La separación entre secciones cumple la función de una línea divisoria sin necesidad de dibujarla: es la proximidad la que comunica la estructura.
- **Similitud.** El mismo par de colores del informe se mantiene en cada pestaña, de modo que el código cromático no debe reaprenderse al navegar.
- **Revelación progresiva.** Cada pestaña presenta el mensaje principal de inmediato y reserva el detalle para la interacción, respetando la capacidad limitada de la memoria de trabajo.

8.2 Ejecución

El dashboard se ejecuta con **streamlit run** desde la carpeta *data/* del repositorio, por la forma en que el script resuelve las rutas de los archivos de datos. Las instrucciones completas, incluidas las variantes para Windows, están documentadas en el **README.md** del proyecto.

9. Evaluación crítica de la solución desarrollada

9.1 Fortalezas

- **Base de datos amplia y balanceada:** dieciséis años, 147 países, 83 idiomas y casi 32.000 títulos otorgan robustez estadística a los patrones identificados.
- **Métricas reales, no supuestos.** El análisis se apoya en indicadores de audiencia efectivamente presentes en los datos, y cada cifra citada en la narrativa fue verificada contra el dataset antes de escribirse.
- **Trazabilidad de las decisiones.** Cada acción de limpieza y cada variable descartada están documentadas con el hallazgo que las justifica, lo que permite auditar el análisis y reproducirlo.
- **Honestidad metodológica.** El proyecto identificó y declaró activamente los límites de sus propios datos — la muestra curada y el sesgo de arranque en frío — en lugar de producir gráficos correctos pero engañosos.
- **Coherencia visual transversal.** La misma paleta y la misma jerarquía operan en el notebook, el dashboard y la presentación.

9.2 Limitaciones

- **Datos de catálogo, no de comportamiento.** Es la limitación más importante. No existen sesiones, tiempo de visualización, dispositivo ni *churn*: el engagement se trabaja con **proxies** (popularidad y volumen de votos), no como medición directa. Cualquier recomendación debe leerse con esa reserva.
- **Cuatro variables inutilizables** (*duration*, *rating*, *date_added*, *budget/revenue*), lo que impidió analizar duración real, número de temporadas, evolución de incorporación al catálogo y rentabilidad.
- **Muestra curada de 1.000 títulos por año**, que impide analizar el crecimiento real del catálogo en el tiempo.
- **Comparación de género restringida a 8 categorías** por incompatibilidad de taxonomías entre fuentes.
- **Sesgo residual en 2024–2025:** aunque mitigado con umbrales, los años más recientes siguen siendo menos comparables que los anteriores.

9.3 Oportunidades de mejora

- **Incorporar datos reales de comportamiento de usuario** desde los sistemas internos (retención, *watch time*, *churn*) para pasar de proxies a medición directa de engagement. Es la mejora de mayor impacto potencial.
- **Desplegar el dashboard en la nube** (Streamlit Community Cloud o servidor interno) para que el Comité lo consulte desde el navegador sin instalar nada localmente.
- **Extraer la limpieza a un módulo compartido** en *src/*, de modo que el notebook y el dashboard importen la misma lógica y no puedan divergir en las cifras si el análisis evoluciona.
- **Unificar la taxonomía de géneros** a nivel de fuente para ampliar la comparación más allá de las ocho categorías actuales.
- **Recuperar las variables financieras** con cobertura suficiente, lo que habilitaría un análisis de retorno de inversión hoy imposible.

10. Conclusiones y recomendaciones

El análisis del catálogo integrado de StreamView Analytics entrega una conclusión clara: **el formato Serie genera consistentemente mayor engagement y mejor percepción de calidad que el formato Película**, y este patrón se sostiene en el tiempo, en los géneros comparables y en los principales mercados internacionales del catálogo. La segunda conclusión, igual de relevante para la operación, es que **popularidad y calidad no son la misma señal** y no pueden gestionarse con un único indicador.

Recomendación	Fundamento en los datos	Acción concreta
1. Reorientar el mix hacia Series originales	7,03 vs. 6,31 en calificación, sostenido 16 años; liderazgo en 5 de 8 géneros comparables; popularidad mediana 3× superior.	Priorizar Animación, Acción y Aventura y Sci-Fi, en los mercados de Japón, China y Corea del Sur, que combinan escala y calificación alta.
2. Proteger Documental como nicho de calidad	Género de Película mejor evaluado del catálogo (7,20), pero con la popularidad promedio más baja (10,46).	Mantener la inversión evaluándola con métricas de calidad y no de alcance masivo.
3. Auditar la inversión en Horror (Película)	Cuarto género más grande del catálogo de Películas, con la calificación más baja de todo el análisis (5,79).	Revisar el volumen de producción antes de asignar nuevo presupuesto al mismo ritmo.
4. Adoptar un KPI compuesto	Correlación popularidad–calificación $r \approx 0,16$: señales casi independientes.	Definir un indicador que combine alcance y calidad para las decisiones de luz verde de contenido.
5. Cruzar con datos de comportamiento real	El engagement se midió con proxies; no existen datos de reproducción en las fuentes disponibles.	Integrar retención y <i>watch time</i> antes de comprometer presupuesto de producción a gran escala.

Estas recomendaciones se sostienen en un análisis reproducible y documentado, no en intuición. Su principal reserva metodológica está explícita: el engagement se midió con aproximaciones y no con datos de reproducción real. Reconocer ese límite es parte de la recomendación, no una salvedad menor.